

# Simulación Monte Carlo y Cadenas de Markov

Módulo 4 : Técnicas computacionales avanzadas para modelar fenómenos sociales  
Concentración en Economía Aplicada y Ciencia de Datos  
ITESM

31 de octubre de 2022



# Método de Monte Carlo

**Idea:** Método para calcular el área bajo una curva. Es una solución estadística al problema de integración.

Supongamos que existe  $M > 0$  tal que  $0 \leq f(\theta) \leq M$  para todo  $\theta \in [a, b]$  y que queremos calcular la integral

$$I = \int_a^b f(\theta) d\theta \quad (1)$$

el valor de la integral es el área bajo la curva  $\phi = f(\theta)$  para  $\theta \in [a, b]$ . Dicha gráfica queda inscrita en el rectángulo  $R = [a, b] \times [0, M]$ .

# Método de Monte Carlo

Sea

$$p(\theta, \phi) = \frac{1}{M(b-a)} I_R(\theta, \phi) \quad (2)$$


Entonces  $p(\theta, \phi)$  corresponde a la función de densidad de una distribución uniforme sobre el rectángulo  $R$ . La integral  $I$  puede entonces estimarse simulando una muestra  $(\theta_1, \phi_1), \dots, (\theta_N, \phi_N)$  de  $p(\theta, \phi)$  y contando cuántos de estos valores caen bajo la curva  $\phi = f(\theta)$ .

El estimador  $\hat{I}$  obtenido es un estimador insesgado de  $I$ .

La varianza del estimador es

$$\text{Var}(\hat{I}) = \frac{I}{N} \{M(b-a) - I\}$$

# Cálculo de $\pi$ por el método de Monte Carlo (Wilkinson and Allen, 1998)



$$\frac{\text{Área del círculo}}{\text{Área del cuadrado}} = \frac{\pi(1)^2}{4} = \frac{\pi}{4}$$


que puede ser descrita por la integral

$$\int_0^1 \sqrt{1-x^2} dx = \frac{\pi}{4}$$

Para calcular  $\pi$  se generan parejas aleatorias de números  $(x_r, y_r)$ , distribuidos uniformemente entre 0 y 1, y contamos cuántos de estos puntos caen dentro del círculo, esto es, si se cumple la igualdad

$$y_r^2 + x_r^2 \leq 1$$

## Pi estimado mediante método de Monte Carlo



# Inferencia bayesiana

- En un contexto de inferencia bayesiana, donde se tiene un modelo muestral  $Y \sim p(y|\theta)$  y una distribución inicial  $p(\theta)$ , la distribución final se calcula de la siguiente forma:

$$p(\theta|y) = \frac{p(y|\theta)p(\theta)}{\int p(\theta')p(y|\theta')d\theta'}$$

- Aún descartando el denominador (el cual se puede interpretar como un factor de escalamiento que hace que la función integre a 1), el cálculo analítico de  $p(\theta|y)$ , en la mayoría de las ocasiones, es complicado.

- Hay distintas técnicas para calcular  $p(\theta|y)$  (aproximación de Laplace, métodos de cuadratura, etc), pero por la capacidad de cómputo disponible las técnicas de simulación de Monte Carlo vía cadenas de Markov (MCMC) han sido mayormente utilizadas.
- La idea de MCMC es **construir una cadena de Markov que sea fácil de simular (a través de un proceso de muestreo) y cuya distribución de equilibrio corresponda a la distribución final de interés.**

# Cadenas de Markov

## Definition

**Cadena de Markov.** Proceso estocástico discreto con estados finitos que cumple la propiedad de Markov.

$$P(X_{t+1} = s | X_1 = s_1, \dots, X_t = s_t) = P(X_{t+1} = s | X_t = s_t)$$



# Cadenas de Markov

**d**

**b**

**c**

## Estados:


d: Dormitorio

b: Bar

c: Comedor

Ejemplo tomado de






La arista representa la posibilidad que un pasajero que está en el dormitorio en el tiempo  $t$  continúe en el dormitorio en el tiempo  $t + 1$ .



Se etiqueta con la probabilidad de que esto suceda (**Probabilidad de transición**)


$$P(X_{t+1} = d \mid X_t = d) = 0,7$$






Arista para la transición del dormitorio al bar

$$P(X_{t+1} = b \mid X_t = d) = 0,1$$




Arista para la transición del dormitorio al comedor

$$P(X_{t+1} = c \mid X_t = d) = 0,2$$



Agregamos todas las transiciones posibles y sus probabilidades.




Las probabilidades de transición pueden representarse de manera matricial:

$$T = \begin{bmatrix} 0,7 & 0,4 & 0,2 \\ 0,1 & 0,4 & 0,2 \\ 0,2 & 0,2 & 0,6 \end{bmatrix} \quad (3)$$

con entradas

$$p_{i,j} \equiv P(X_{t+1} = i \mid X_t = j)$$




Matriz de probabilidad de estado:

$$T = \begin{bmatrix} 0,7 & 0,4 & 0,2 \\ 0,1 & 0,4 & 0,2 \\ 0,2 & 0,2 & 0,6 \end{bmatrix}$$

La dinámica para la distribución de probabilidad puede expresarse:

$$\begin{bmatrix} P(X_{t+1} = d) \\ P(X_{t+1} = b) \\ P(X_{t+1} = c) \end{bmatrix} = T \begin{bmatrix} P(X_t = d) \\ P(X_t = b) \\ P(X_t = c) \end{bmatrix} \quad (4)$$

$$P(X_{t+1}) = TP(X_t) \quad (5)$$



Si sabemos que el pasajero se encuentra en el dormitorio al tiempo  $t = 0$ :

$$P(X_0) = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = P_0$$


Al tiempo siguiente la distribución es:

$$P(X_1) = TP_0 = P_1$$

$$P(X_1) = \begin{bmatrix} 0,7 & 0,4 & 0,2 \\ 0,1 & 0,4 & 0,2 \\ 0,2 & 0,2 & 0,6 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

$$P(X_1) = \begin{bmatrix} 0,7 \\ 0,1 \\ 0,2 \end{bmatrix}$$





Para tiempos futuros

$$P(X_t) = TP(X_{t-1}) \equiv P_t$$


$$P_1 = TP_0$$

$$P_2 = TP_1$$

$$\begin{bmatrix} 0,7 & 0,4 & 0,2 \\ 0,1 & 0,4 & 0,2 \\ 0,2 & 0,2 & 0,6 \end{bmatrix} \begin{bmatrix} 0,7 \\ 0,2 \\ 0,1 \end{bmatrix}$$

$$= \begin{bmatrix} 0,57 \\ 0,15 \\ 0,28 \end{bmatrix}$$

$$TTP_0 = T^2P_0$$



Para tiempos futuros

$$P_t = T^t P_0$$

# Algoritmo de Metropolis (Theodoridis, 2020)

- La distribución propuesta cambia con el tiempo siguiendo la evolución de una cadena de Markov.
- La cadena se construye de manera que su matriz de transición tenga la distribución deseada  $p(x)$  la cual es invariante.
- La distribución propuesta depende del valor del estado previo,  $x_{n-1}$ , esto es,  $q(\cdot|x_{n-1})$ .
- Es decir, generar una nueva muestra (un nuevo estado) depende del valor del estado previo.

---

## Algorithm 1: Algoritmo Metropolis (Theodoridis, 2020)

---

Sea la distribución deseada  $p(\cdot)$

Escoge una distribución de propuesta  $q(\cdot|\cdot)$

Escoge el valor del estado inicial  $x_0$

**for**  $n = 1, 2, \dots, N$  **do**

    Toma un valor  $x \sim q(\cdot|x_{n-1})$

    Calcula el valor de aceptación

    /\* Si la probabilidad de  $p(x)$  es más grande que la de  $p(x_{n-1})$ , entonces se  
    acepta la nueva muestra. En caso contrario, esta es aceptada-rechazada en  
    base a su valor relativo \*/

$$\alpha(x|x_{n-1}) = \min \left\{ 1, \frac{p(x)}{p(x_{n-1})} \right\}$$

    Escoge  $u \sim U(0, 1)$

**if**  $u \leq \alpha(x|x_{n-1})$  **then**

$x_n = x$

**else**

$x_n = x_{n-1}$

**end if**

**end for**

# Ejemplo con una distribución normal con varianza conocida

Sea  $\theta \sim \text{normal}(\mu, \tau^2)$  y  $\{y_1, \dots, y_n | \theta\} \sim \text{i.i.d. normal}(\theta, \sigma^2)$ , la distribución posterior de  $\theta$  es  $\text{normal}(\mu_n, \tau_n^2)$  donde

$$\mu_n = \bar{y} \frac{\frac{n}{\sigma^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}} + \mu \frac{\frac{n}{\tau^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$
$$\tau_n^2 = \frac{1}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$

Supongamos que  $\sigma^2 = 1, \tau^2 = 10, \mu = 5, n = 5$  y  $y = \{9, 37, 10, 18, 9, 16, 11, 60, 10, 33\}$ .

Con estos datos,  $\mu_n = 10,03$  y  $\tau_n^2 = 0,2$ , de manera que  $p(\theta | y) = \text{dnorm}(10,03, 0,44)$

- Supongamos que no podemos obtener la distribución final, así que usamos el algoritmo Metropolis.
- La proporción de aceptación de un valor propuesto  $\theta^*$  con respecto al valor actual  $\theta^{(s)}$  es

$$r = \frac{p(\theta^*|y)}{p(\theta^{(s)}|y)} = \left( \frac{\prod_{i=1}^n \text{dnorm}(y_i, \theta^*, \sigma)}{\prod_{i=1}^n \text{dnorm}(y_i, \theta^{(s)}, \sigma)} \right) \times \left( \frac{\text{dnorm}(\theta^*, \mu, \tau)}{\text{dnorm}(\theta^{(s)}, \mu, \tau)} \right)$$

- En algunos casos calcular  $r$  directamente puede ser inestable, por lo que se sugiere calcular el logaritmo de  $r$

$$\log r = \sum_{i=1}^n \left[ \log \text{dnorm}(y_i, \theta^*, \sigma) - \log \text{dnorm}(y_i, \theta^{(s)}, \sigma) \right] + \log \text{dnorm}(\theta^*, \mu, \tau) - \log \text{dnorm}(\theta^{(s)}, \mu, \tau)$$

- Manteniendo las cosas en la escala logarítmica, el valor propuesto se acepta si  $\log u < \log r$ , donde  $u$  es una muestra de una distribución uniforme en  $(0, 1)$ .

# References I

- Theodoridis, S. (2020). *Machine Learning. A Bayesian and Optimization Perspective*. Academic Press, second edition edition.
- Wilkinson, B. and Allen, M. (1998). *Parallel Programming: Techniques and Applications Using Networked Workstations and Parallel Computers*. Prentice-Hall, Inc., USA.